

# Informe de Investigación Profunda: Esquemas de Asimilación de Datos para el Modelo WRF

## Fundamentos Teóricos y Matemáticos de la Asimilación de Datos

La asimilación de datos constituye la piedra angular de la predicción numérica del tiempo moderna, sirviendo como el puente entre el mundo observable y los modelos computacionales <sup>20</sup>. Su propósito fundamental es generar condiciones iniciales precisas para los modelos de predicción numérica del tiempo (NWP), abordando un problema intrínsecamente subdeterminado donde aproximadamente  $10^5$  observaciones son insuficientes para inicializar modelos con  $10^7$  grados de libertad <sup>20</sup>. Este proceso combina información incompleta de modelos dinámicos, datos de mediciones esparsas y corruptas, y conocimiento previo sobre el estado del sistema para producir una trayectoria optimizada que describe la evolución atmosférica <sup>10</sup>. La historia de la asimilación de datos está intrínsecamente ligada a la historia de la meteorología numérica desde su concepción. El concepto fue propuesto por Vilhelm Bjerknes en 1904, quien postuló un procedimiento de dos pasos: primero, un paso de análisis (que hoy conocemos como asimilación de datos) para generar condiciones iniciales, seguido de un paso de predicción que resuelve el problema de valor inicial <sup>20</sup>. Los primeros intentos exitosos de predecir el tiempo numéricamente comenzaron en la década de 1950, utilizando los primeros ordenadores digitales como el ENIAC, lo que marcó el inicio de la era operativa de la predicción numérica del tiempo <sup>20</sup>.

Dentro del amplio espectro de técnicas de asimilación de datos, dos paradigmas dominan el campo: el nudging (relajamiento) y los métodos variacionales, con el 3D-Var (Variación Tridimensional) siendo uno de los más fundamentales. El nudging es un método relativamente simple e intuitivo que introduce fuerzas de relajación artificial en las ecuaciones dinámicas del modelo <sup>34</sup>. Estas fuerzas actúan como fuentes o sumideros ficticios que gradualmente ajustan el estado del modelo hacia un campo de referencia, como un reanálisis global o un conjunto de observaciones directas, durante un período de tiempo predefinido <sup>20 34</sup>. El objetivo es mantener la simulación del modelo coherente con las observaciones conocidas a gran escala, especialmente cerca de los límites del dominio regional. Existen varias implementaciones del nudging dentro del sistema WRF. El nudging de grilla (grid\_fdda=1) aplica una fuerza de relajación a cada punto de la rejilla tridimensional hacia un campo de análisis interpolado, lo cual es adecuado para simulaciones de baja resolución <sup>34</sup>. El nudging de observación (obs\_nudge\_opt=1) es más sofisticado, ya que ajusta el modelo basándose en un promedio ponderado de las observaciones cercanas en espacio y tiempo, lo que permite incorporar datos asincrónicos o de alta frecuencia <sup>34</sup>. Una variante crucial es el nudging espectral (spectral nudging), que se aplica principalmente en modelos regionales para asegurar la consistencia a gran escala. Este método no relaja todos los componentes del campo del modelo, sino solo aquellos correspondientes a ondas largas (bajas números de onda), mientras que las ondas cortas (altas números de onda), asociadas a fenómenos mesoscópicos como tormentas convectivas, pueden

evolucionar libremente<sup>31 32 33</sup>. Esto es vital para evitar que errores en las condiciones de borde globales distorsionen los patrones a gran escala dentro del dominio regional sin suprimir la actividad local de alta resolución<sup>34</sup>. La principal desventaja del nudging es que introduce fuerzas no físicas en el modelo, lo que lo hace inadecuado para estudios dinámicos o de balances de energía en el dominio y período donde se aplica<sup>34</sup>.

Por otro lado, los métodos variacionales, como el 3D-Var, adoptan un enfoque mucho más sofisticado basado en la optimización matemática. El 3D-Var busca encontrar el estado del sistema (el "análisis") que representa el equilibrio óptimo entre la información contenida en un modelo previo (el "background") y la nueva información proveniente de las observaciones<sup>9 10</sup>. Este equilibrio se encuentra minimizando una función de costo,  $J(u)$ , que cuantifica la discrepancia entre el estado final y el background, así como la discrepancia entre las observaciones y su representación en el modelo<sup>10 25</sup>. La forma general de esta función de costo es:

$$J(u) = \frac{1}{2}(w - h(u))^T R^{-1}(w - h(u)) + \frac{1}{2}(u - u_b)^T B^{-1}(u - u_b)$$

donde  $u$  es el vector del estado analizado,  $u_b$  es el vector del estado de fondo (background),  $w$  es el vector de observaciones,  $h(u)$  es el operador de observación que transforma el estado del modelo al espacio de las observaciones, y  $B$  y  $R$  son las matrices de covarianza de error del fondo y de las observaciones, respectivamente<sup>10 20</sup>. El primer término penaliza la discrepancia entre las observaciones y sus valores simulados, mientras que el segundo término penaliza la distancia entre el estado analizado y el estado de fondo, con pesos dados por la inversa de las matrices de error<sup>10</sup>. La solución de este problema de optimización proporciona un análisis que es estadísticamente óptimo bajo la hipótesis de que tanto los errores del fondo como los errores de las observaciones siguen una distribución gaussiana<sup>9</sup>. La implementación práctica del 3D-Var en sistemas como WRFDA implica una serie de entradas críticas, incluyendo el estado de fondo, la matriz de error de fondo, la matriz de error de observación, los datos de observación y el operador de observación<sup>9</sup>. Las matrices de error de fondo son particularmente importantes, ya que codifican la estructura de correlación espacial y vertical del error del modelo; estas se pueden estimar mediante métodos como el NMC (National Meteorological Center) o modeladas usando filtros recursivos<sup>26 27</sup>. Aunque potente, el 3D-Var presenta desafíos significativos, como la necesidad de especificar y calibrar cuidadosamente las matrices de error, lo que puede ser un proceso iterativo y costoso computacionalmente<sup>9 26</sup>. Además, a diferencia de los filtros de Kalman, el 3D-Var utiliza una única y fija matriz de error de fondo en cada ciclo de asimilación, sin actualizarla con la información recién obtenida<sup>9</sup>. Esta limitación ha impulsado el desarrollo de métodos más avanzados como los Filtros de Kalman Ensemble (EnKF), que estiman la covarianza del error de fondo directamente a partir de un ensamble de miembros de pronóstico, permitiendo una representación más realista de la incertidumbre<sup>10 20</sup>. Otro método variacional más avanzado es el 4D-Var, que extiende el concepto de 3D-Var para incorporar la dinámica del modelo a lo largo de un intervalo de tiempo (la ventana de asimilación), minimizando una función de costo que evalúa las discrepancias en múltiples momentos dentro de esa ventana<sup>10</sup>. A continuación, se presenta una tabla que resume las características clave de los principales métodos de asimilación discutidos.

| Característica            | Nudging                                                                        | 3D-Var                                                                   | 4D-Var                                                                                       | Filtros de Kalman Ensemble (EnKF)                                                  |
|---------------------------|--------------------------------------------------------------------------------|--------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| Principio Fundamental     | Relajación continua hacia un campo de referencia <sup>34</sup>                 | Optimización variacional para un estado óptimo <sup>10</sup>             | Optimización variacional sobre un intervalo de tiempo <sup>10</sup>                          | Propagación secuencial de estadísticas del estado y su covarianza <sup>10</sup>    |
| Manejo de Observaciones   | Indirecto (relajación hacia un campo que contiene observaciones) <sup>34</sup> | Directo (penalizado explícitamente en la función de costo) <sup>10</sup> | Directo (penalizado explícitamente en la función de costo a través del tiempo) <sup>10</sup> | Directo (actualización del ensamble basada en innovaciones) <sup>10</sup>          |
| Matriz de Error de Fondo  | Implícito, basado en la calidad del campo de referencia                        | Explícita, predefinida y fija en cada ciclo <sup>9</sup>                 | Explícita, calculada sobre toda la ventana de asimilación <sup>10</sup>                      | Implícita, estimada a partir de un ensamble de miembros <sup>10 20</sup>           |
| Complejidad Computacional | Baja <sup>5</sup>                                                              | Alta <sup>5</sup>                                                        | Muy Alta <sup>5</sup>                                                                        | Muy Alta <sup>5</sup>                                                              |
| Manejo de No Linealidades | Limitado, asume linealidad local                                               | Mejorado con formulaciones incrementales <sup>26</sup>                   | Muy bueno, maneja la no linealidad del modelo dinámico <sup>10</sup>                         | Bueno, inherentemente adaptativo <sup>10</sup>                                     |
| Aplicación Principal      | Corrección de condiciones de borde, simulaciones a largo plazo <sup>34</sup>   | Generación de análisis iniciales de alta calidad <sup>1</sup>            | Óptima generación de análisis para modelos de alta resolución <sup>10</sup>                  | Sistemas de pronóstico probabilístico, asimilación en tiempo real <sup>13 16</sup> |

Este panorama teórico establece la base para comprender las fortalezas y debilidades de cada método. Mientras que el nudging ofrece una solución pragmática y computacionalmente eficiente para problemas de consistencia a gran escala, los métodos variacionales como el 3D-Var proporcionan un marco formal y riguroso para integrar datos de manera óptima, lo que resulta en un análisis inicial de mayor calidad, especialmente cuando se dispone de un conjunto diverso de observaciones. La elección entre ellos no es trivial y debe estar guiada por los objetivos específicos del estudio, la disponibilidad de recursos computacionales y la naturaleza de los fenómenos meteorológicos de interés.

# Análisis Comparativo Detallado: Nudging frente a 3D-Var

La decisión entre utilizar nudging o 3D-Var para mejorar las predicciones del modelo WRF es un dilema metodológico central en la predicción numérica del tiempo. Ambos enfoques buscan el mismo objetivo: obtener las mejores condiciones iniciales posibles. Sin embargo, sus principios fundamentales, implicaciones computacionales y rendimiento en diversas circunstancias climáticas difieren significativamente. Un análisis profundo de la literatura científica revela un consenso claro en ciertos contextos, aunque también existen matices que dependen críticamente de la variable de interés y del fenómeno a predecir. La evidencia empírica más contundente sugiere que, para la predicción de fenómenos convectivos intensos y organizaciones mesoscópicas complejas, el 3D-Var supera consistentemente al nudging. Un estudio comparativo exhaustivo realizado en la costa occidental de la India durante un evento de lluvia intensa demostró que la implementación de 3D-Var significativamente mejoró la precisión de los parámetros meteorológicos en comparación tanto con una simulación de control (CNTL) sin asimilación como con una simulación de nudging (NUD)<sup>1,2</sup>. Los resultados cuantitativos fueron abrumadores: en el análisis inicial, el experimento de 3D-Var (3DV) reprodujo flujos de viento mucho más fuertes y estructuras de vorticidad que estaban ausentes tanto en los reanálisis de entrada (FNL) como en la simulación de nudging<sup>1</sup>. Específicamente, a nivel 850 hPa, 3DV capturó vientos de 16 – 20 m/s cerca de la costa de Maharashtra, alineándose perfectamente con las mediciones de radiosondeos, mientras que FNL y NUD fallaron en reproducir este patrón crucial<sup>2</sup>. De manera similar, a nivel 500 hPa, 3DV representó correctamente vientos de 8 – 12 m/s sobre el océano Ártico y la región interior de Maharashtra y Karnataka, una característica que no aparecía en las demás simulaciones<sup>1,2</sup>. Estas mejoras en la estructura dinámica se tradujeron directamente en una predicción de precipitación notablemente superior. Al comparar las predicciones con datos satelitales de TRMM, el experimento 3DV mostró correlaciones espaciales significativamente más altas (0.78 para el día 1) y errores cuadráticos medios (RMSE) considerablemente menores (18.20 mm para el día 1) en comparación con CNTL (CC: 0.28, RMSE: 26.45 mm) y NUD (CC: 0.42, RMSE: 21.64 mm)<sup>2</sup>. Las puntuaciones Equitables de Amenaza (ETS), que miden la habilidad predictiva del modelo, también fueron consistentemente más altas para 3DV en todas las umbrales de precipitación evaluadas<sup>1,2</sup>. La razón fundamental de esta superioridad radica en la capacidad del 3D-Var para incorporar directamente datos heterogéneos —como radiosondeos, datos de buceadores, aviones y vectores de movimiento de nubes derivados de satélites— en el cálculo del análisis<sup>1</sup>. Este proceso permite una mejor inicialización de características mesoscópicas como los ciclones tropicales en el medio troposfera (MTC), que son cruciales para la organización convectiva y la generación de lluvia intensa<sup>1</sup>.

A pesar de esta evidencia sólida, el nudging no debe ser descartado como una técnica inferior en absoluto. Su eficacia depende del objetivo específico de la simulación. Por ejemplo, en un estudio enfocado en la simulación de la dispersión de contaminantes, se encontró que el nudging ofrecía un rendimiento superior a 3D-Var y 4D-Var para variables críticas como la insolación, las nubes, la velocidad y la dirección del viento<sup>3</sup>. Esto subraya una verdad fundamental: no existe un único esquema de asimilación universalmente superior. La elección debe ser contextual. Otra ventaja distintiva del nudging es su menor costo computacional. Un estudio que comparó el nudging de rayos con 3D-Var para la predicción de un derecho convectivo encontró que el método de nudging

era computacionalmente mucho menos exigente <sup>5</sup> . Como resultado, el nudging podía aplicarse con una frecuencia mucho mayor (cada 10 minutos) en comparación con el 3D-Var (cada 30 minutos), lo que permitió una actualización más rápida de la información convectiva en el modelo <sup>5</sup> . Esta flexibilidad temporal puede ser crucial para la predicción a muy corto plazo. Sin embargo, la aplicación de nudging, especialmente el nudging de grilla, requiere precaución. Introducir fuerzas de relajación puede crear inbalance en el campo del modelo, lo que puede llevar a la generación de ondas de gravedad espurias y a una degradación de la calidad de la predicción si no se aplica con cuidado, particularmente en la capa límite planetaria (PBL) <sup>34</sup> . En contraste, el 3D-Var, al buscar un estado físico plausible que sea consistente con el modelo, tiende a producir análisis más equilibrados. La siguiente tabla resume y compara directamente las características de ambos métodos en función de la evidencia extraída de las fuentes proporcionadas.

| Característica                 | Nudging                                                                                                                                 | 3D-Var                                                                                                                   |
|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| Principio de Funcionamiento    | Introduce fuerzas de relajación para llevar el modelo hacia un campo de referencia <sup>34</sup> .                                      | Minimiza una función de costo para encontrar un estado óptimo que equilibra el fondo y las observaciones <sup>10</sup> . |
| Complejidad de Implementación  | Menor, con opciones predefinidas en el WRF <sup>34</sup> .                                                                              | Mayor, requiere configuración detallada de matrices de error y otros parámetros <sup>9</sup> .                           |
| Costo Computacional            | Bajo, especialmente en comparación con 3D-Var <sup>35</sup> .                                                                           | Alto, debido a las iteraciones de optimización y el cálculo de gradientes <sup>59</sup> .                                |
| Manejo de Observaciones        | Indirecto, a través de un campo de referencia que puede haber sido generado con observaciones <sup>34</sup> .                           | Directo, la discrepancia con las observaciones se penaliza explícitamente en la función de costo <sup>10</sup> .         |
| Impacto en Dinámica Convectiva | Puede ser efectivo pero puede introducir inbalance si no se gestiona bien <sup>34</sup> .                                               | Superior en la representación de estructuras dinámicas y termodinámicas complejas como MTCs <sup>12</sup> .              |
| Mejor Aplicación Demostrada    | Simulación de dispersión de contaminantes <sup>3</sup> , corrección de condiciones de borde, modelos de alta resolución <sup>20</sup> . | Predicción de lluvia intensa, ciclones mesoscálicos, y eventos con fuerte organización convectiva <sup>12</sup> .        |
| Flexibilidad Temporal          | Alta, puede aplicarse con alta frecuencia (ej. cada 10 min) <sup>5</sup> .                                                              | Más lenta, debido al alto costo computacional (ej. cada 30 min) <sup>5</sup> .                                           |

| Característica                 | Nudging                                                                                                                        | 3D-Var                                                                                                                                     |
|--------------------------------|--------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| Resultados Cuantitativos Clave | RMSE para viento a 850 hPa: 5.02 m/s (vs. 3.66 m/s para 3DV) <sup>2</sup> .<br>ETS más bajos para precipitación <sup>1</sup> . | CC para viento a 850 hPa: 0.72 (vs. 0.53 para NUD) <sup>2</sup> . RMSE para precipitación: 18.20 mm (vs. 21.64 mm para NUD) <sup>2</sup> . |

Esta comparación matizada es crucial para el anteproyecto del usuario. Si el objetivo principal es mejorar la predicción de eventos de precipitación intensa, como podrían ser los responsables del "Zonda", la evidencia sugiere abrumadoramente que el 3D-Var es la opción preferible. Sin embargo, si el proyecto también involucra la simulación de la dispersión de polvo, aerosoles o la interacción con la superficie, el nudging podría ofrecer beneficios adicionales para ciertas variables. La decisión final debe basarse en una clara definición de los objetivos de investigación y en una evaluación honesta de los recursos computacionales disponibles. Para un proyecto de doctorado, proponer un experimento que compare sistemáticamente ambos métodos no solo es viable, sino que también constituiría una contribución académica valiosa, validando empíricamente estas diferencias teóricas en el contexto geográfico específico de interés del usuario.

## Técnicas Avanzadas de Asimilación y Su Relevancia en Sudamérica

Para un proyecto de investigación doctoral, la elección entre 3D-Var y Nudging, aunque fundamental, representa solo el punto de partida. La frontera de la asimilación de datos está dominada por técnicas más sofisticadas que abordan las limitaciones de los métodos tradicionales, como la dependencia de covarianzas de error fijas y la dificultad para gestionar la incertidumbre en sistemas no lineales. En el contexto sudamericano, y particularmente en Argentina, la investigación y la aplicación operativa han convergido en torno a un grupo de tecnologías avanzadas que combinan los principios de los filtros de Kalman con los modelos regionales. El Local Ensemble Transform Kalman Filter (LETKF) acoplado con el modelo WRF se ha convertido en una herramienta de vanguardia utilizada extensivamente por centros de investigación y servicios meteorológicos de renombre <sup>13 14 15 16 31 32 33</sup>. Este enfoque representa un cambio paradigmático respecto a los métodos variacionales estáticos. En lugar de utilizar una única y fija matriz de error de fondo ( $B$ ), el EnKF genera un ensamble de miembros de pronóstico. La covarianza del error de fondo se estima entonces a partir de la varianza y la covarianza de este ensamble, proporcionando una representación dinámica y adaptativa de la incertidumbre del sistema atmosférico <sup>10 20</sup>. Esta capacidad de estimar la covarianza de error de forma empírica es una de sus mayores ventajas, ya que elimina la necesidad de especular sobre la estructura compleja de las correlaciones de error, que es un desafío central en los métodos variacionales <sup>10</sup>. Además, el EnKF maneja naturalmente las no linealidades del modelo atmosférico, ya que la propagación de la incertidumbre a través del ensamble captura eficazmente los efectos no lineales que se perderían en una aproximación lineal del 3D-Var <sup>10</sup>.

La relevancia de estas técnicas avanzadas para el anteproyecto del usuario es inmensa. Múltiples estudios realizados en Argentina demuestran el impacto positivo y medible de los sistemas WRF-LETKF. Por ejemplo, la implementación de un sistema multi-esquema, que utiliza diferentes configuraciones de parametrizaciones físicas para cada miembro del ensamble, ha mostrado mejorar

consistentemente tanto los análisis como los pronósticos en comparación con configuraciones de física única<sup>13 16</sup>. De manera similar, la inclusión de nuevos tipos de observaciones, como los perfiles verticales de temperatura y humedad del Atmospheric Infrared Sounder (AIRS), ha demostrado tener un impacto positivo significativo, especialmente en regiones como Sudamérica donde los radiosondeos son escasos<sup>13 16</sup>. Un estudio específico sobre la precipitación intensa del 6 y 7 de diciembre de 2012 encontró que los miembros del ensamble del WRF-LETKF superaron en muchas ocasiones al modelo WRF-GFS sin asimilación, evidenciando un impacto neto positivo de la asimilación de datos regionales<sup>13</sup>. Más recientemente, un informe técnico del Servicio Meteorológico Nacional de Argentina (SMN) confirmó que iniciar pronósticos probabilísticos con análisis regionales de LETKF-WRF tiene un impacto positivo, aunque limitado en el tiempo y en áreas específicas, mejorando particularmente la predicción de los vientos a 10 metros y la representación espacial de la precipitación<sup>14</sup>. Estos hallazgos indican que el enfoque de ensamble no es solo una curiosidad teórica, sino una práctica probada y exitosa para mejorar la predicción numérica del tiempo en el contexto sudamericano.

Además del uso de filtros de Kalman ensemble, otro concepto avanzado de gran importancia en la literatura especializada sobre Sudamérica es el nudging espectral (SN). Este método, como se mencionó anteriormente, es una forma de nudging diseñada específicamente para mitigar los problemas asociados con las condiciones de borde en los modelos regionales<sup>31 32 33</sup>. Cuando un modelo regional como WRF se integra con condiciones de borde de un modelo global (como GEFS o GFS), cualquier error presente en el modelo global puede penetrar en el dominio regional y degradar la calidad de la simulación, especialmente a medida que avanza el tiempo<sup>32</sup>. El SN aborda esto manteniendo la fase y la amplitud de las ondas a gran escala (generalmente con longitudes de onda mayores a ~1000 km) del modelo regional alineadas con las del modelo global, mientras que las ondas a menor escala se desarrollan libremente<sup>31 34</sup>. Esto garantiza que el sistema regional se mantenga en sintonía con la circulación a gran escala global, que es el forzamiento primario de la atmósfera, sin sacrificar la resolución mesoscópica para resolver fenómenos locales. Un estudio que evaluó el impacto del SN en un sistema LETKF-WRF sobre Sudamérica concluyó que el SN mejora el rendimiento de las variables de circulación y termo-dinámicas tanto en los análisis como en los pronósticos, demostrando su viabilidad y potencial para aumentar la fiabilidad de las predicciones regionales<sup>32</sup>. La implementación del SN es computacionalmente barata, ya que añade un costo insignificante a la simulación, lo que lo convierte en una herramienta extremadamente rentable para mejorar la calidad de las condiciones de borde<sup>31</sup>. Por lo tanto, para cualquier proyecto de investigación que utilice WRF en Sudamérica, la consideración de cómo manejar las condiciones de borde a través del SN es una práctica estándar y recomendada. La combinación de un filtro de Kalman ensemble para la asimilación interna y el nudging espectral para la gestión de las condiciones de borde representa el estado del arte en la predicción numérica regional.

## Diseño de Experimentos y Métricas de Evaluación Cuantitativa

Un anteproyecto de tesis doctoral de calidad no puede limitarse a una simple descripción de los métodos. Requiere un plan experimental riguroso y una estrategia de evaluación cuantitativa para justificar la elección metodológica y demostrar la contribución original del trabajo. Para el caso del usuario, el objetivo es completar un anteproyecto de asimilación de datos para el modelo WRF,



utilizando datos históricos. El diseño de un experimento comparativo es la estrategia más sólida para abordar la incertidumbre inicial sobre si usar 3D-Var o Nudging. Este enfoque no solo proporciona una respuesta a la pregunta inicial, sino que también permite un análisis más profundo de los mecanismos de mejora y las limitaciones de cada técnica. Se propone un diseño de experimento que consta de tres simulaciones principales, cada una con un conjunto de condiciones iniciales y de borde diferentes.

El primer experimento es el Experimento de Control (CNTL). Este será la línea base de referencia. Se ejecutará el modelo WRF utilizando condiciones iniciales y de borde provenientes de un reanálisis global de alta resolución, como el Global Forecast System (GFS) del NCEP<sup>12 13</sup>. Crucialmente, en este experimento no se realizará ninguna asimilación de datos locales. Este escenario representa la predicción estándar, sin la influencia de los datos específicos de la región de interés, y servirá como un punto de comparación fundamental para cuantificar el impacto de cualquier técnica de asimilación posterior.

El segundo experimento es el Experimento de Nudging (NUD). Aquí se implementará un esquema de nudging, con una fuerte recomendación de utilizar el nudging espectral (spectral nudging)<sup>31 32 33</sup>. Dado que el modelo regional estará forzado por un modelo global, es imperativo utilizar SN para corregir la fase y la amplitud de las ondas a gran escala, asegurando que el sistema regional permanezca en sintonía con la circulación global sin ser perturbado por errores de borde<sup>34</sup>. Las variables a nudgear típicamente incluyen el viento zonal (U), meridional (V), la altura geopotencial (HGT) y la temperatura (T), pero no la humedad, para preservar la física de formación de nubes<sup>31</sup>. Los parámetros clave, como la frecuencia de nudging (por ejemplo, cada 6 horas), la intensidad (coeficiente de relajación) y el número de onda máximo a nudgear (que determina la longitud de onda de ~1000 km), deberán configurarse según las mejores prácticas documentadas<sup>31</sup>. Este experimento evaluará la capacidad de un método relativamente simple y computacionalmente económico para mejorar las condiciones iniciales y de borde.

El tercer experimento es el Experimento de 3D-Var (3DV). Este es el componente más técnico del plan. Se utilizará el sistema de asimilación de datos de WRF (WRFDA) para ejecutar un ciclo de 3D-Var<sup>27</sup>. El estado de fondo provendrá del mismo reanálisis global utilizado para el experimento de control (CNTL). El objetivo será asimilar el conjunto de datos históricos disponibles en [http://www.unsjcuencas.com.ar/eta\\_pites.php](http://www.unsjcuencas.com.ar/eta_pites.php), junto con cualquier otro dato de observación conveniente y disponible para la región (p. ej., datos de radiosondeos, datos de satélite de vectores de viento, etc.), si la infraestructura de datos lo permite. El proceso de 3D-Var generará un nuevo estado del sistema (el análisis) que servirá como la condición inicial para una nueva simulación de pronóstico. Este experimento pondrá a prueba la capacidad de un método variacional más sofisticado para integrar información de observaciones heterogéneas y crear un análisis inicial de mayor calidad, especialmente para fenómenos mesoscópicos.

Finalmente, para un proyecto de doctorado ambicioso, se podría considerar un cuarto experimento: Experimento de EnKF. Aunque más arriesgado y computacionalmente intensivo, la exploración de un sistema basado en ensambles (potencialmente simplificado) sería una contribución original y significativa. Este experimento requeriría la creación de un pequeño ensamble de miembros de pronóstico (p. ej., 10-20 miembros) con perturbaciones en las condiciones iniciales o en los parámetros físicos, y la aplicación de un algoritmo de EnKF para actualizar el estado del ensamble en



cada paso de tiempo. Aunque la implementación completa de un sistema como LETKF es una tarea monumental, un prototipo conceptual o un análisis teórico sobre su potencial impacto sería valioso. Este diseño experimental comparativo permite un análisis multifacético del problema y proporciona una base sólida para la defensa metodológica del anteproyecto.

Una vez ejecutados los experimentos, la evaluación del impacto de la asimilación de datos requiere un conjunto de métricas cuantitativas rigurosas. Estas métricas deben seleccionarse en función de las variables de interés y los objetivos de predicción. Para campos continuos como la temperatura, el viento y la altura geopotencial, las métricas estándar incluyen el Error Cuadrático Medio (RMSE), la Correlación Cruzada (CC) y el Bias. Estas métricas se calcularán en varios niveles de presión (p. ej., 850 hPa y 500 hPa) para evaluar el impacto en la estructura vertical de la atmósfera<sup>12</sup>. Para la predicción de precipitación, que es una variable discreta y con muchos ceros, se utilizan métricas de contingencia basadas en una tabla de 2x2 (verdaderos positivos, falsos positivos, verdaderos negativos, falsos negativos). Entre las más comunes se encuentran la Probabilidad de Detección (POD), la Tasa de Alarmas Falsas (FAR), el Sesgo de Frecuencia (FBIAS) y el Score de Amenaza Equitable (ETS)<sup>13,21</sup>. El ETS es particularmente útil porque penaliza tanto los falsos positivos como los falsos negativos, proporcionando una medida más equilibrada de la habilidad del modelo para predecir la ocurrencia y ubicación de la precipitación<sup>121</sup>. Para evaluar la estructura espacial de la precipitación, se puede utilizar la Puntuación de Habilidad de Fracción (FSS), que mide la habilidad del pronóstico para replicar la estructura de los patrones de precipitación en una vecindad de una cierta escala espacial<sup>21</sup>. Finalmente, un análisis de las "innovaciones" (la diferencia entre las observaciones y el estado del modelo antes de la asimilación) puede proporcionar diagnósticos valiosos sobre la calidad y el impacto de las observaciones individuales<sup>26</sup>. La selección y aplicación de estas métricas permitirá una conclusión clara y basada en evidencia sobre qué esquema de asimilación, si es que alguno, produce las mejores predicciones para los objetivos del proyecto.

## Síntesis Analítica y Recomendaciones Estratégicas para el Anteproyecto

Tras un análisis exhaustivo de los fundamentos teóricos, el desempeño comparativo y las técnicas avanzadas de asimilación de datos, es posible formular una serie de recomendaciones estratégicas claras para guiar el anteproyecto del usuario. La incertidumbre inicial sobre la elección entre 3D-Var y Nudging no debe verse como un obstáculo, sino como una oportunidad para diseñar un estudio metódico y riguroso. La evidencia acumulada en la literatura científica proporciona una hoja de ruta clara, aunque con matices que deben ser cuidadosamente considerados. En esencia, la decisión no es simplemente elegir un método, sino seleccionar un paradigma metodológico que se alinee con los objetivos de investigación específicos, los recursos disponibles y el contexto geográfico del estudio.

La recomendación más directa y basada en la evidencia es que, para el objetivo implícito de mejorar la predicción de fenómenos meteorológicos a través del modelo WRF, el 3D-Var es el método superior, siempre y cuando se implemente correctamente y se le provea de un conjunto diverso de observaciones. Los estudios comparativos sobre eventos de lluvia intensa han demostrado de manera concluyente que 3D-Var produce análisis iniciales de mayor calidad, con una mejor representación de la estructura dinámica y termodinámica, lo que se traduce directamente en una predicción de

precipitación significativamente más precisa<sup>12</sup>. La capacidad del 3D-Var para integrar directamente datos heterogéneos (radiosondeos, satélites, etc.) en un marco de optimización formal es su principal ventaja sobre el nudging, que opera de manera indirecta a través de un campo de referencia<sup>1</sup>. Por lo tanto, si el objetivo principal del proyecto es la predicción de eventos convectivos, como las tormentas eléctricas o los sistemas de precipitación intensa, centrarse en la implementación y evaluación del 3D-Var es la estrategia más prometedora.

Sin embargo, el nudging no debe ser completamente ignorado. Su rol principal reside en la corrección de la fase y la amplitud de las ondas a gran escala, especialmente en modelos regionales forzados por modelos globales<sup>31 34</sup>. En el contexto de Sudamérica, donde la circulación a gran escala juega un papel crucial en la variabilidad climática, la implementación de nudging espectral (SN) es una práctica estándar y altamente recomendada para asegurar la coherencia del modelo regional con el forzamiento global<sup>31 32 33</sup>. Por lo tanto, el diseño experimental más robusto no debería presentar una dicotomía "3D-Var vs. Nudging", sino un enfoque comparativo más sofisticado. Se recomienda encarecidamente que el anteproyecto proponga un experimento comparativo formal que incluya al menos tres simulaciones: una de control (sin asimilación), una con nudging espectral (para el control de la escala grande) y una con 3D-Var (para aprovechar la información de las observaciones locales). Esta estrategia permitirá al usuario no solo responder a su pregunta inicial, sino también investigar la interacción entre la asimilación de datos locales (3D-Var) y la necesidad de mantener la coherencia a gran escala (SN).

Para un proyecto de doctorado, el horizonte de investigación debe ir más allá de estos métodos tradicionales. La literatura sobre el Sistema Nacional Meteorológico de Argentina demuestra de manera inequívoca el poder y la relevancia de los filtros de Kalman ensemble (EnKF), como el LETKF<sup>13 14 16</sup>. Estos métodos, al estimar la covarianza del error de fondo de forma empírica a partir de un ensamble, superan una de las limitaciones más significativas de los métodos variacionales estáticos<sup>10</sup>. La inclusión de un componente de EnKF, incluso si es conceptual o se limita a un análisis teórico de su potencial impacto, posicionaría el trabajo en la vanguardia de la investigación en asimilación de datos. Podría proponerse un análisis de sensibilidad que explore cómo la estimación de la incertidumbre a través de un ensamble podría cambiar los resultados obtenidos con 3D-Var y Nudging. Esta dimensión adicional añadiría una capa de originalidad y profundidad metodológica al anteproyecto.

Finalmente, es crucial abordar las limitaciones prácticas y las consideraciones metodológicas. La implementación de 3D-Var y, especialmente, EnKF, es computacionalmente intensiva<sup>5</sup>. El usuario debe realizar una estimación realista de los recursos computacionales necesarios para ejecutar los ciclos de asimilación y las simulaciones de pronóstico. Además, la calidad de los resultados dependerá críticamente de la calidad y densidad de los datos de observación disponibles. Los datos de la web **[unsjcuencas.com.ar](http://unsjcuencas.com.ar)** serán valiosos, pero es importante reconocer que podrían tener lagunas espaciales o temporales que afecten el impacto de la asimilación<sup>15</sup>. La calibración de los parámetros de los esquemas de asimilación (tiempos de relajación, coeficientes de peso, etc.) es un proceso iterativo que requiere experiencia y paciencia<sup>9</sup>. El anteproyecto debe incluir un capítulo dedicado a estas consideraciones, describiendo el plan para validar los resultados utilizando un conjunto de datos independiente para evitar el sobreajuste.

En síntesis, la recomendación final para el anteproyecto del usuario es la siguiente: 1. Clarificar los Objetivos: Definir con precisión qué fenómeno meteorológico se pretende predecir con mayor detalle. 2. Proponer un Diseño Experimental Robusto: Diseñar un experimento comparativo que incluya al menos un modelo de control, un modelo con nudging espectral y un modelo con 3D-Var. Utilizar un conjunto de datos histórico para los ciclos de asimilación y un conjunto diferente para la verificación. 3. Seleccionar Métricas de Evaluación Adecuadas: Utilizar RMSE, CC para campos dinámicos y ETS, POD, FAR para la precipitación, junto con análisis de innovaciones. 4. Incorporar un Componente de Innovación: Explorar brevemente el potencial de un sistema basado en EnKF para demostrar un entendimiento profundo de las técnicas avanzadas y posicionar el trabajo en la vanguardia de la investigación. 5. Documentar Limitaciones: Ser transparente sobre los desafíos computacionales, la calidad de los datos y los procesos de calibración.

Siguiendo esta hoja de ruta, el usuario podrá transformar su incertidumbre inicial en un anteproyecto de investigación sólido, bien fundamentado y con un claro potencial para generar contribuciones significativas al campo de la predicción numérica del tiempo.

---

## Referencia

1. A Comparative Study on Performance of Analysis Nudging ... <https://onlinelibrary.wiley.com/doi/10.5402/2012/523942>
2. A Comparative Study on Performance of Analysis Nudging and ... [https://www.researchgate.net/publication/258403907\\_A\\_Comparative\\_Study\\_on\\_Performance\\_of\\_Analysis\\_Nudging\\_and\\_3DVAR\\_in\\_Simulation\\_of\\_a\\_Heavy\\_Rainfall\\_Event\\_Using\\_WRF\\_Modeling\\_System](https://www.researchgate.net/publication/258403907_A_Comparative_Study_on_Performance_of_Analysis_Nudging_and_3DVAR_in_Simulation_of_a_Heavy_Rainfall_Event_Using_WRF_Modeling_System)
3. Comparison of Meteorological Simulations created using ... <https://ams.confex.com/ams/96Annual/webprogram/Paper289723.html>
4. Comparison between a multi-variate nudging method and ... <https://www.cambridge.org/core/journals/journal-of-glaciology/article/comparison-between-a-multivariate-nudging-method-and-the-ensemble-kalman-filter-for-seaice-data-assimilation/6B5BAE0A22A5828F22402EDC7D3AC44A>
5. Evaluation of a Cloud-Scale Lightning Data Assimilation ... <https://journals.ametsoc.org/view/journals/mwre/142/1/mwr-d-13-00142.1.pdf>
6. Building a model - wflow documentation - Read the Docs [https://wflow.readthedocs.io/en/latest/wflow\\_building.html](https://wflow.readthedocs.io/en/latest/wflow_building.html)
7. Weather Research & Forecasting Model (WRF) - NCAR/MMM <https://www.mmm.ucar.edu/models/wrf>
8. Environmental Modeling Framework Invasiveness [https://digitalcommons.tacoma.uw.edu/tech\\_pub/22/](https://digitalcommons.tacoma.uw.edu/tech_pub/22/)
9. 13.1. Calculation algorithm “3DVAR” [https://docs.salome-platform.org/latest/gui/ADAO/en/ref\\_algorithm\\_3DVAR.html](https://docs.salome-platform.org/latest/gui/ADAO/en/ref_algorithm_3DVAR.html)

10. PyDA: A Hands-On Introduction to Dynamical Data ... <https://www.mdpi.com/2311-5521/5/4/225>
11. PyDDA: A Pythonic Direct Data Assimilation Framework for ... <https://openresearchsoftware.metajnl.com/articles/10.5334/jors.264>
12. WRF MNA - UNLP <https://mna.fcaglp.unlp.edu.ar/>
13. Asimilación de datos reales a escala regional en Argentina [https://bibliotecadigital.exactas.uba.ar/download/tesis/tesis\\_n6387\\_Dillon.pdf](https://bibliotecadigital.exactas.uba.ar/download/tesis/tesis_n6387_Dillon.pdf)
14. Evaluación del Sistema de Asimilación de datos y Pronóstico ... [https://repositoriosdigitales.mincyt.gob.ar/vufind/Record/ELABRIGO\\_f663c75470d2390b5e63de7650195f4a](https://repositoriosdigitales.mincyt.gob.ar/vufind/Record/ELABRIGO_f663c75470d2390b5e63de7650195f4a)
15. implementación de metodología efso para evaluar el ... [https://www.researchgate.net/publication/367117689\\_IMPLEMENTACION\\_DE\\_METODOLOGIA\\_EFSO\\_PARA\\_EVALUAR\\_EL\\_IMPACTO\\_DE\\_OBSERVACIONES\\_ASIMILADAS\\_EN\\_UN\\_SISTEMA\\_DE\\_ASIMILACION\\_Y\\_PRONOSTICO\\_REGIONAL](https://www.researchgate.net/publication/367117689_IMPLEMENTACION_DE_METODOLOGIA_EFSO_PARA_EVALUAR_EL_IMPACTO_DE_OBSERVACIONES_ASIMILADAS_EN_UN_SISTEMA_DE_ASIMILACION_Y_PRONOSTICO_REGIONAL)
16. Sensibilidad de un sistema de asimilación de datos por ... <https://ri.conicet.gov.ar/handle/11336/175177>
17. Leveraging Data-Driven Weather Models for Improving ... <https://journals.ametsoc.org/view/journals/wefo/40/9/WAF-D-24-0139.1.xml>
18. Progress, challenges, and future steps in data assimilation for ... <https://rmets.onlinelibrary.wiley.com/doi/10.1002/asl.1130>
19. Data Assimilation <https://www.aoml.noaa.gov/hrd/themes/0/>
20. Data Assimilation in Numerical Weather Prediction models [https://indico.cern.ch/event/289770/contributions/664473/attachments/541326/746202/DA\\_CERN\\_Perianez.pdf](https://indico.cern.ch/event/289770/contributions/664473/attachments/541326/746202/DA_CERN_Perianez.pdf)
21. Improving the lightning forecast with the WRF model and ... <https://www.sciencedirect.com/science/article/pii/S0169809524001649>
22. Generative Data Assimilation of Sparse Weather Station ... <https://arxiv.org/html/2406.16947v2>
23. What is data assimilation and why does it matter in weather ... <https://spire.com/blog/weather-climate/what-is-data-assimilation-and-why-does-it-matter-in-weather-modeling/>
24. Implementation of a 3D-Var system for atmospheric ... <https://amt.copernicus.org/articles/6/3563/>
25. A Three-Dimensional Variational (3DVAR) Data Assimilation [https://opensky.ucar.edu/system/files/2024-08/technotes\\_309.pdf](https://opensky.ucar.edu/system/files/2024-08/technotes_309.pdf)
26. (PDF) Implementation of a 3D-Var system for atmospheric ... [https://www.researchgate.net/publication/258747993\\_Implementation\\_of\\_a\\_3D-Var\\_system\\_for\\_atmospheric\\_profiling\\_data\\_assimilation\\_into\\_the\\_RAMS\\_model\\_Initial\\_results](https://www.researchgate.net/publication/258747993_Implementation_of_a_3D-Var_system_for_atmospheric_profiling_data_assimilation_into_the_RAMS_model_Initial_results)

27. Constraining a 3DVAR Radar Data Assimilation System with ... <https://journals.ametsoc.org/view/journals/apme/55/3/jamc-d-15-0010.1.pdf>
28. 3D - Var data assimilation using a variational autoencoder <https://rmets.onlinelibrary.wiley.com/doi/full/10.1002/qj.4708>
29. Discrete-Storm Water-Table Fluctuation Method to Estimate ... [https://wwwrcamnl.wr.usgs.gov/uzf/abs\\_pubs/papers/nimmo.15.episodicrecharge-complete.groundwater.pdf](https://wwwrcamnl.wr.usgs.gov/uzf/abs_pubs/papers/nimmo.15.episodicrecharge-complete.groundwater.pdf)
30. PITES SAN JUAN <http://www.unsjcuencas.com.ar/webpites/Vesperr/index.html>
31. iglesias.pdf - Meteorológica <http://www.meteorologica.org.ar/wp-content/uploads/2022/04/iglesias.pdf>
32. Impacto de la inclusión del nudging espectral en los análisis y ... <https://ri.conicet.gov.ar/handle/11336/196014>
33. Listar por tema "LETKF- WRF" - Repositorio Institucional SMN <https://repositorio.smn.gov.ar/browse?type=subject&value=LETKF-+WRF>
34. Nudging [https://www2.mmm.ucar.edu/wrf/users/tutorial/presentation\\_pdfs/202101/dudhia\\_nudging.pdf](https://www2.mmm.ucar.edu/wrf/users/tutorial/presentation_pdfs/202101/dudhia_nudging.pdf)